

TALLER INTEGRADOR DE INFERENCIA BAYESIANA  
Maestría en Minería de Datos, FCEN, UBA

# Caso A

## La Herrumbre

*Identificación forense bayesiana*

Equipo de Inferencia Bayesiana, UBA  
Abril de 2026

## 1 Presentación del caso

El 14 de enero de 2024, en el paraje El Bajo (Partido de La Herrumbre, Provincia de Buenos Aires) se recuperaron restos óseos humanos parcialmente degradados (causa 1872/2024). El Laboratorio Forense Municipal procesó las muestras y la Fiscalía Departamental restringió el espacio de hipótesis a cinco candidatos compatibles ( $C_1$  a  $C_5$ ) tras un cribado demográfico.

Se convoca a peritos estadísticos independientes para producir un dictamen pericial bayesiano sobre seis hipótesis:  $H_0$  residual (los restos no corresponden a ninguno de los cinco) y  $H_1$  a  $H_5$  (los cinco candidatos), a partir de tres líneas evidenciales: antropométrica (sexo, edad, intervalo post-mortem o IPM), de fuentes abiertas (testimonios, redes sociales, registros municipales) y genética (verosimilitudes por pares pre-computadas sobre una base poblacional STR, Short Tandem Repeats). Toda la información del caso está publicada en el sitio del Municipio de La Herrumbre.

## 2 Objetivos

- Construir la posterior  $P(H_i | E)$  por enumeración sobre las seis hipótesis, en escala logarítmica para evitar pérdida numérica.
- Combinar tres líneas evidenciales — antropométrica, fuentes abiertas y genética — multiplicativamente bajo el supuesto de independencia condicional dado  $H_i$ , supuesto que se declara y se discute.
- Cuantificar el aporte de la línea genética con la divergencia KL (Kullback–Leibler) entre la posterior antes y después de incorporarla.
- Analizar sensibilidad cambiando el prior y el peso  $\lambda$  de la línea genética.
- Tomar una decisión forense con umbral en la probabilidad posterior.

**Lo que NO se pide.** El caso usa terminología forense y genética como contexto narrativo, pero el ejercicio es *de inferencia bayesiana*, no de antropología ni de genética poblacional. **El Laboratorio Forense Municipal entrega los cocientes de verosimilitud (LR) ya computados.** La tarea estadística empieza ahí: combinarlos con el prior, normalizar, evaluar el peso de cada línea y decidir.

## 3 Consigna

El dictamen pericial tiene cuatro entregables:

1. **Tabla pericial.** Seis filas ( $H_0$  a  $H_5$ ) con columnas  $\pi_i$ ,  $\log \text{LR}_{\text{ant}}$ ,  $\log \text{LR}_{\text{abi}}$ ,  $\log \text{LR}_{\text{gen}}$ ,  $\log_{10} \text{LR}_{\text{total}}$  y  $P(H_i | E)$  bajo el prior elegido.
2. **Aporte informacional de la línea genética.** Divergencia KL entre la posterior sin y con la genética,  $\text{KL}(P(H | E_{\text{full}}) \| P(H | E_{\text{ant,abi}}))$ , en bits o en nats. Interpretación.
3. **Sensibilidad.** (i) Posterior bajo prior uniforme y bajo prior demográfico. (ii) Posterior bajo  $\lambda \in \{0; 0,3; 0,5; 0,7; 1,0\}$ , donde  $\lambda$  pondera la línea genética en escala log:  $\log \text{LR}_{\text{gen}} \rightarrow \lambda \cdot \log \text{LR}_{\text{gen}}$ .

4. **Decisión forense.** Reportar el candidato con mayor posterior y su masa. Declarar identificación positiva si esa masa supera un umbral pre-fijado (sugerido 0,95); declarar indeterminación si no lo supera.

## 4 Cómo abordar el caso, paso a paso

El análisis se construye en seis etapas. Las primeras tres son carpintería: leer los informes y los CSV, declarar el prior, cargar las tablas de LR del laboratorio. Las tres últimas son donde aparece la inferencia: combinar las tres líneas, cuantificar el aporte de la genética y mover los parámetros para ver qué cambia y qué se mantiene. Conviene avanzar en orden y *no saltarse el paso 1*; el caso premia el dictamen trazable, no la velocidad.

### *Paso 1. Lectura del caso, antes de tocar código*

Antes de abrir R o Python, recorrer el sitio del Municipio. Leer el informe antropológico (página `/laboratorio/informe_restos.html`) y los datos crudos de fuentes abiertas (página `/busqueda/datos/`) hasta tener una intuición sobre cada candidato: edad declarada, ocupación, vínculos familiares, última actividad registrada. Esa lectura es la que va a sostener el prior demográfico y la interpretación de los LR del paso 4.

### *Paso 2. Espacio de hipótesis y prior*

Las seis hipótesis son  $H_0$  (residual: “no corresponde a ninguno de los cinco”) y  $H_1, \dots, H_5$  (cada candidato). El prior  $\pi_i$  asigna masa a cada una *antes de ver la evidencia*.

Se reportan dos versiones del prior. La primera, **uniforme**,  $\pi_i = 1/6$  para los seis: no privilegia a nadie y sirve como baseline metodológico. La segunda, **demográfico**, usa la edad declarada de cada candidato (en `/laboratorio/datos/perfiles_candidatos.csv`) y la distribución poblacional de `registro_civil/datos/base_poblacional.csv` para favorecer candidatos compatibles con el corredor migratorio. Como punto de partida orientativo, el grupo puede arrancar con el vector  $(\pi_0, \pi_1, \dots, \pi_5) = (0,20; 0,18; 0,22; 0,12; 0,20; 0,08)$ , normalizado, y refinarlo si la lectura del paso 1 sugiere otra distribución de plausibilidades.

### *Paso 3. Cocientes de verosimilitud por línea*

Un LR es el cociente  $P(E | H_i) / P(E | H_0)$ : cuántas veces más probable es observar la evidencia  $E$  si la hipótesis es  $H_i$  que si es  $H_0$ . Las tres líneas se asumen condicionalmente independientes dado  $H_i$ , de modo que los LR **se multiplican**; equivalentemente, sus logaritmos se suman.

El sitio publica los LR ya calculados, en `/laboratorio/datos/tablas_*.csv`, bajo dos convenciones por bloque: *estricta* (A1, B1, G1) y *moderada* (A2, B2, G2). El grupo **declara qué convención usa por bloque** (por ejemplo, A1 + B2 + G1) y deja las restantes para el análisis de sensibilidad. La elección no es estadística sino metodológica: se documenta cuál supuesto del laboratorio se acepta. Por construcción  $LR(H_0) = 1$  en las tres líneas, así que la fila de  $H_0$  aparece en la tabla pericial sólo para que las posteriores sumen uno y para visualizar la masa residual asignada a “otra persona”.

*Paso 4. Posterior por composición progresiva*

Es útil construir la posterior *en tres pasos sucesivos*, observando cómo se mueve la masa al sumar cada línea. Esto hace explícito el aporte relativo de cada bloque y prepara el análisis de sensibilidad.

1. Posterior con **sólo el prior y la línea antropométrica**. Concentración esperable: moderada; varios candidatos siguen siendo plausibles.
2. Posterior con **prior + antropométrica + fuentes abiertas**. Concentración esperable: mayor; algunos candidatos se descartan.
3. Posterior **completa, con genética incluida**. La genética suele dominar: para algunos candidatos  $\log_{10} \text{LR}_{\text{gen}}$  supera los 25 órdenes de magnitud y la posterior se concentra fuerte en uno o dos.

Conviene reportar las tres posteriores en una sola figura para que se vea cómo cada línea afila o desplaza la masa.

*Paso 5. Aporte informacional de la genética*

La pregunta es cuánta información agrega la línea genética sobre lo que ya sabíamos con antropometría y fuentes abiertas. Se cuantifica con la divergencia KL entre la posterior provisional (pasos 4.1 y 4.2 combinados) y la posterior final (paso 4.3):

$$\text{KL}(P(H | E_{\text{full}}) || P(H | E_{\text{ant,abi}})) = \sum_{i=0}^5 P(H_i | E_{\text{full}}) \log \frac{P(H_i | E_{\text{full}})}{P(H_i | E_{\text{ant,abi}})}.$$

Reportar en bits (logaritmo en base 2) o en nats (logaritmo natural). Una KL grande significa que la genética movió la posterior de manera sustantiva; una KL chica, que la genética confirmó lo que ya estaba establecido. Ambas lecturas son legítimas y se interpretan en el dictamen.

*Paso 6. Sensibilidad y decisión forense*

Dos análisis de sensibilidad obligatorios. El primero, **prior**: comparar la posterior bajo prior uniforme y bajo prior demográfico. ¿La identificación cambia? Si no cambia, la conclusión es robusta a la elección del prior. El segundo, **peso de la línea genética**: la genética concentra mucha evidencia, y conviene saber cuán dependiente es la conclusión de esa única línea. Para eso se la pondera con un escalar  $\lambda$  en escala log:  $\log \text{LR}_{\text{gen}} \rightarrow \lambda \cdot \log \text{LR}_{\text{gen}}$ . Con  $\lambda = 0$  la genética se ignora; con  $\lambda = 1$  se usa entera. Reportar la posterior para  $\lambda \in \{0; 0,3; 0,5; 0,7; 1,0\}$  y observar a qué valor de  $\lambda$  el candidato más probable cambia, si llega a hacerlo.

Con eso se cierra la **decisión forense**. Si el candidato con mayor posterior supera el umbral pre-fijado (sugerido 0,95) bajo *las dos* configuraciones del prior y bajo  $\lambda \geq 0,5$ , se declara identificación positiva. Si la identificación se sostiene sólo con la genética entera, conviene declarar indeterminación o reportar la conclusión condicionada al supuesto.

## 5 Notas de implementación

- **Mapecto de identificadores.** Los testimonios usan `id_persona` con valores 1 a 5; las tablas genéticas usan `candidato_id` con valores C1\_ESCOBAR a C5\_BARRIENTOS. La correspondencia 1:1 figura en `busqueda/datos/diccionario.md`.
- **Escala log10 vs natural.** La columna `log10_LR` de los CSV reporta  $\log_{10}$  LR. Para sumar logaritmos en R:  $\ln LR = \log_{10} LR \cdot \ln(10)$ . No volver a restar  $\log LR(H_0)$ : la columna ya es relativa a  $H_0$ .
- **Trabajar en escala logarítmica desde el principio.** Los LR de la línea genética pueden alcanzar  $10^{28}$ , magnitud no representable por los tipos numéricos habituales. Sumar logaritmos no tiene ese problema. Para normalizar la posterior sin perder precisión, restar el máximo del log-numerador antes de exponenciar.
- **Tratamiento de testimonios correlacionados.** Las convenciones B1 y B2 del laboratorio ya internalizan el descuento por correlación familiar entre testigos del mismo candidato (B1 estricta, B2 moderada). El grupo no necesita reimplementar el descuento.

## 6 Recursos

Toda la información del caso vive en el sitio del Municipio de La Herrumbre. La URL se entrega aparte. Las páginas relevantes y sus archivos descargables son:

| Recurso                                             | Ubicación en el sitio                                            |
|-----------------------------------------------------|------------------------------------------------------------------|
| Informe antropológico de los restos                 | <code>/laboratorio/informe_restos.html</code>                    |
| Tablas periciales de LR (A, B, G)                   | <code>/laboratorio/tablas_periciales.html</code>                 |
| LR antropométrico por candidato (A1, A2)            | <code>/laboratorio/datos/tablas_A_antropometrica.csv</code>      |
| LR de fuentes abiertas (B1, B2)                     | <code>/laboratorio/datos/tablas_B_osint.csv</code>               |
| LR genético robusto (G1, G2)                        | <code>/laboratorio/datos/tablas_G_robustez.csv</code>            |
| Tabla resumen de las 8 combinaciones                | <code>/laboratorio/datos/tablas_resumen_combinaciones.csv</code> |
| Datos crudos de fuentes abiertas (lectura del caso) | <code>/busqueda/datos/ con diccionario.md</code>                 |
| Pedigrees declarados y base poblacional             | <code>/registro_civil/</code>                                    |

**Herramientas sugeridas.** R con `tidyverse` (`readr`, `dplyr`) es la pila recomendada; Python también es válido. El paquete del curso `ibUBA` provee `kl_discrete()` para la divergencia entre posteriores y `lr_update_multi()` como utilidad para combinar cocientes de verosimilitud bajo independencia condicional.

## 7 Entregable

**Presentación oral en formato PPT** (15 minutos más 5 de preguntas). Es el entregable principal y debe articular: planteo del caso, hipótesis y prior, supuesto de independencia condicional declarado, tabla pericial con la posterior, KL al incorporar la línea genética, sensibilidad ( $\lambda$  y prior) y decisión forense con umbral.

**Código en R o Python reproduciendo los análisis.** Archivo `.R`, `.Rmd`, `.py` o documento ejecutable equivalente, con semilla fija, que corra desde los CSV descargados del sitio y reproduzca

todos los resultados de la presentación. Se entrega el día de la defensa. Es el único entregable escrito.

### *Cronograma sugerido*

*Es solamente orientativo.* Cada grupo organiza su trabajo internamente con la libertad que considere; las fechas y los hitos sirven como guía para sostener el ritmo, no como entregas obligatorias intermedias. Lo único exigible es la **defensa final del 23/06**.

| Clase        | Duración   | Hito sugerido al cierre                                                                                                                        |
|--------------|------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| 12/05        | 1 h        | Recorrido del sitio, formación de grupos, descarga de las tablas periciales y lectura del informe antropológico (paso 1).                      |
| 19/05        | 1 h        | Convención por bloque declarada (A, B, G). Prior elegido. Primer cómputo de la posterior corriendo (pasos 2 y 3).                              |
| 26/05        | <b>3 h</b> | Trabajo con docentes. Posterior por composición progresiva: con antropometría sola, con antropometría más fuentes abiertas, completa (paso 4). |
| 02/06        | 1 h        | Aporte de la línea genética: divergencia KL entre posterior provisional y final (paso 5).                                                      |
| 09/06        | 1 h        | Sensibilidad sobre el peso $\lambda$ de la genética y sobre la convención del laboratorio (paso 6).                                            |
| 16/06        | 1 h        | Pre-defensa: armado de la presentación y argumentación de la decisión forense.                                                                 |
| <b>23/06</b> | —          | <b>Defensa final y entrega del código.</b>                                                                                                     |

*Ejercicio didáctico, datos simulados. La Herrumbre, sus habitantes, la Oficina Municipal y el Laboratorio Forense son construcciones ficticias.*